

风控 AI Native 平台建设思路

从传统规则驱动，升级到可理解、可编排、可回放、可闭环的智能风控平台

1 传统风控系统的问题

1. 多模态信号割裂：

图像 / OCR / ASR / 标题 / 账号历史分散，缺少统一理解。

2. 规则野蛮增殖：

阈值、关键词、账号历史、设备关系、豁免策略不断叠加。

3. 难解释难维护：

难回答“为什么被判”“证据在哪里”“哪条规则导致”。

4. 灰区场景吃力：

对擦边、引流、合理语境等复杂 case 判断不稳定。

2 AI 带来的核心变化

不是替代规则，而是重构判断方式



从规则堆叠，
转向“风险理解 +
动作编排 +
策略约束”



识别 Agent：
理解风险模式，
组织证据链
与反证



处置 Agent：
在 Policy 约束下
生成动作建议




Trace / Eval：
支持回放、评估、
复盘与持续优化

AI 的价值不在“判得更狠”，而在“判得更清楚、更可控”。

3 核心架构 / 主链路

Policy 边界与合规约束



MCP / Tool Gateway
(按需调用)

- 模型结果
- 账号画像
- 相似样本
- 设备关系
- 策略规则
- 审核队列
- 执行工具
- 通知与申诉
- 权限控制 / 预算控制 / 审计记录 / 降级兜底

4 关键能力与安全闭环

关键能力

- 跨模态风险理解
- 证据链组织与反证识别
- 动态编排与人机协同
- 误杀 / 漏放 / 新型风险模式复盘

安全与治理

- Agent 可增强判断，但不能越过治理边界
- 高风险 / 灰区 case 必须人审兜底
- 高敏工具与数据最小权限访问
- 所有关键决策可 Trace、可审计、可回放



5 渐进式落地路径

- Step 1 辅助理解**
先做灰区样本的人审辅助、证据链展示
- Step 2 处置建议**
在 Policy 约束下给出动作建议，提升分流效率
- Step 3 闭环优化**
沉淀风险模式库，持续优化模型、Prompt、Policy 与审核 SOP

不是让 AI 直接接管风控，而是把传统风控经验
升级为可信的 AI Native 决策基础设施。

AI Native 核心优势总览 VS 传统风控系统劣势

以色情/低俗视频内容风控场景为例：从“分数判断”走向“风险理解、证据链与持续优化”



传统流程

规则/模型判定 + 人工审核为中心
关注的是：风险分数够不够高？

VS


AI Native

Agent 编排 + 多模态理解 + 证据链 + 人机协同闭环为中心
关注的是：这是什么风险模式、证据在哪里、如何处置、如何持续优化？



传统风控系统劣势

固定流水线、分数驱动、规则膨胀、人审兜底



- 缺少整体理解**
图像、OCR、ASR、账号画像、规则引擎彼此割裂。系统能看到局部信号，却难以判断完整风险模式，例如“色情擦边 + 私域引流”的组合风险。
- 规则越来越复杂**
大量 if-else、阈值、例外和特例不断叠加。规则互相冲突、上线慢、解释困难，策略维护高度依赖工程。
- 人审压力大**
模型不确定、人审兜底；规则冲突、人审兜底；新型风险、人审兜底。审核员需要自己查视频、查历史、查规则，工作量大且一致性难保证。
- 证据链弱**
系统常常只输出“命中规则 ID”和“模型分数”，但无法清楚回答：哪一帧有问题？哪一句话有问题？为什么建议限流或下架？
- 复盘和优化慢**
误杀、漏放、申诉等问题通常依赖人工导数、复盘、改阈值、重标注，优化周期长，难以及时应对变化。
- 新风险适应慢**
面对新型擦边话术、封面模板、账号团伙行为，传统系统往往需要重新写规则、改模型、排期上线，响应速度慢。

传统特征

模型打分 规则阈值 人工兜底 模块割裂 解释弱 复盘慢

AI Native 核心优势

风险理解、动态编排、证据驱动、持续优化



- 从分数判断到风险理解**
不只是看 porn_score、text_score，而是识别“风险模式 + 风险等级 + 置信度 + 证据 + 反证 + 建议动作”。
- 多模态证据链更完整**
综合关键帧、标题、OCR、ASR、账号历史、相似样本等多源信息，形成结构化证据链，更容易判断、更容易解释。
- Agent 动态编排**
不再是固定流水线，而是按场景调用不同 Agent：识别、处置、发现、调查、反思，实时与离线协同。
- 规则从主决策变成策略边界**
识别由 Agent 负责，规则主要定义 allowed actions、forbidden actions、人审要求与治理红线，更可配置、更可解释。
- 人机协同效率更高**
机器先整理关键帧、上下文、相似案例和建议动作，人工集中处理灰区、高风险、高影响决策，审核效率和一致性更高。
- 可解释、可审计、可回放**
通过 Trace 记录调用了哪些工具、形成了哪些证据、为什么建议该动作、人审是否采纳、申诉结果如何。
- 更快发现新风险**
发现 Agent、调查 Agent 可离线扫描举报、申诉、相似内容、账号异常和异常模式，更快识别新型擦边和引流模式。
- 形成持续优化闭环**
通过 Trace + Eval + 反思 Agent 分析误杀、漏放、人审分歧和策略效果，持续优化模型、策略、SOP 和审核培训。

AI Native 关键词


Agent 编排 多模态理解 Policy MCP 证据链 人机协同 Trace Eval 反思闭环

同一条风险视频，AI Native 会输出什么？

- 风险模式：**
色情擦边 + 私域引流
- 置信度：** 0.86
- 证据：**
 - 第18-42帧存在性暗示动作
 - 标题：“私信有惊喜”
 - OCR：“加我看更多”
 - 账号有 2 次低俗警告
 - 与 12 条已下架视频相似
- 建议动作：**
暂不公开 + 评论限制 + 高优人审

核心对比

维度	传统流程	AI Native
核心逻辑	模型打分 + 规则阈值 + 人审	Agent 编排 + 多模态理解 + 证据链
判断方式	分数驱动	风险模式理解 + 场景判断
规则角色	主决策逻辑	策略边界与处置约束
人工角色	大量兜底审核	灰区判断与治理决策
可解释性	命中规则、模型分数	证据链、策略依据、可回放 Trace
优化方式	人工复盘、改规则	Trace + Eval + 反思 Agent 持续优化




传统流程是在判断“风险分数够不够高”；
AI Native 是在理解“这是什么风险模式、证据在哪里、应该如何处置、后续如何优化”。

视频发布真实运行链路：

色情 / 涉毒场景 AI Native 内容风控方案

方案目标：从真实运行链路视角，展示视频发布后在色情/低俗与涉毒场景下，系统如何完成接入、预处理、模型初筛、Agent 编排、工具调用、风险识别、处置、人审、执行、Trace/Eval 与离线优化的全流程闭环。

1 真实运行链路总览



2 链路分层说明

顺序	真实运行节点	节点定位	是否主链路必经	说明
1	用户发布视频	业务事件入口	是	用户提交视频、标题、描述、封面、账号、设备等信息
2	接入网关	基础安全与合法性校验	是	鉴权、限流、格式校验、文件安全、去重、生成 video_id
3	内容预处理	多模态素材生成	是	抽帧、关键帧、封面、ASR、OCR、文本清洗、视频切片
4	轻量模型初筛	低延迟风险信号提取	通常是	先用低成本模型判断是否需要进入 Agent 深度链路
5	Orchestrator	场景判断与编排	是	判断低风险快速通过, 还是进入识别 Agent / 处置 Agent
6	识别 Agent	风险理解与证据链组织	条件触发	中高风险、灰区、复杂风险进入
7	MCP / Tool Gateway	侧边能力调用层	被调用	Agent 按需调用, 不是视频请求主动流经
8	处置 Agent	动作编排	条件触发	将风险理解转成通过、限流、暂不公开、人审、拦截等动作
9	人工审核工作台	高价值人工判断节点	条件触发	处理灰区、高风险、高影响、申诉、专项样本
10	执行与用户触达	动作落地	是	发布、拦截、下架、限流、评论限制、账号处罚、通知、申诉入口
11	Trace / Eval	可回放、可审计、可评估	是	记录输入、模型、Agent 调用、策略、执行、人审、申诉结果
12	离线发现 / 调查 / 反思	持续治理	异步	发现新风险、调查团伙、复盘误杀漏放、优化策略/模型/SOP

规则图例

- ✓ 必经 / 主链路
- 条件触发
- ⦿ 被调用 / 侧边层
- ⦿ 异步 / 闭环优化

核心原则

- 主链路流转的是 case / video / 风险结果;
- MCP / Tool 是 Agent 运行时按需调用的受控能力通道。

3 主链路详细设计 (示例)

3.1 用户发布视频

用户在客户端提交视频发布请求, 形成一个 video_publish_event。

输入示例 (色情 / 低俗)

```
{  "video_file": "upload.mp4",  "title": "懂的来, 私信有惊喜",  "description": "更多内容看主页",  "user_id": "user_123",  "device_id": "device_abc",  "ip": "x.x.x.x"}
```

输出示例

```
{  "publish_event_id": "event_001",  "event_type": "video_publish",  "raw_payload_ref": "raw_payload_001"}
```

3.2 接入网关

入口侧确定性校验, 不做复杂内容语义判断。

输入示例

```
{  "publish_event_id": "event_001",  "video_file": "upload.mp4",  "title": "懂的来, 私信有惊喜",  "description": "更多内容看主页",  "user_id": "user_123",  "device_id": "device_abc",  "ip": "x.x.x.x"}
```

输出示例

```
{  "video_id": "video_789",  "case_id": "case_789",  "upload_status": "accepted",  "need_content_review": true,  "basic_risk_flag": {    "new_account": true,    "suspicious_title": true  }}
```

3.3 内容预处理

将原始视频帧转换成模型和 Agent 可理解的多模态素材。

输出示例 (色情 / 低俗)

```
{  "video_id": "video_789",  "key_frames": [    { "frame_id": "frame_016", "timestamp": "00:16" },    { "frame_id": "frame_042", "timestamp": "00:42" }  ],  "asr_text": "懂的可以私信我",  "ocr_text": "懂的来私信有惊喜",  "clean_title": "懂的来私信有惊喜",  "clean_description": "更多内容看主页"}
```

输出示例 (涉毒)

```
{  "key_frames": [    { "frame_id": "frame_012", "hint": "疑似样本" },    { "frame_id": "frame_037", "hint": "疑似样本" }  ],  "asr_text": "很相像, 老地方见",  "ocr_text": "VX-XXXXXXX 私聊有货"}
```

3.4 轻量模型初筛

低成本模型快速判断风险信号, 决定是否进入深度链路。

输出示例 (涉毒)

```
{  "video_id": "video_789",  "overall_risk_score": 0.87,  "risk_level": "high",  "risk_types": [ "drug_trafficking" ],  "hit_reasons": [    "画面疑似毒品相关物品",    "语音/文字涉毒关键词"  ],  "need_deep_review": true}
```

3.5 Orchestrator 判断场景

判断低风险快速放行, 还是进入识别 Agent/处置 Agent。

输出示例 (高风险进入链路)

```
{  "video_id": "video_789",  "route": "deep_review",  "target_agents": [    "识别 Agent",    "处置 Agent"  ],  "priority": "high",  "timeout": 60}
```

3.6 识别 / 处置 / 执行

Agent 理解风险并编排动作, 必要时调用工具能力并落地执行。

识别 Agent: 理解风险、组织证据链

按需调用 MCP / Tool 补证

处置 Agent: 选择处置动作

调用 Policy / Review / Enforcement / Notification 工具

执行与用户触达: 动作落地

技术要点与保障

低延迟高并发
接入与初筛低延迟, 保障用户体验

多模态理解
视频、音频、文本、图像全面理解

可追溯可审计
全链路 Trace, 支持回放与合规审计

闭环持续优化
离线复盘反馈模型、策略、SOP 与 Agent 能力

安全合规
隐私保护、最小化原则、权限与水印管控

备注: 示例数据仅用于说明流程, 实际以系统实现为准。

核心总结

角色	传统职责	AI Native 新职责
策略运营	写规则、定处罚、看误杀漏放、培训审核员	定义风险模式、证据标准、反证逻辑、Agent SOP、Eval 标准
算法工程师	训练分类模型、输出风险分数	构建多模态风险信号、相似样本召回、证据定位、模型与 Agent 协同
研发工程师	开发审核后台、规则引擎、处罚服务	搭建 Orchestrator、MCP / Tool Gateway、Trace 系统、Agent 运行时与权限控制

策略运营定义判断框架，算法工程师提供信号与证据，研发工程师保障 Agent 安全、稳定、可审计地运行。



1 | 策略运营： 从规则运营到风险理解设计师




职责变化


	过去	现在
风险定义	定义违规类型	定义风险模式、证据链、反证条件
规则配置	写 if-else 规则	设计 Policy、Agent Prompt、SOP、动作边界
人审管理	培训审核员看什么	设计 Agent 给人审展示什么证据
处置策略	配置处罚等级	约束处置 Agent 的 allowed / forbidden actions
复盘优化	看误杀漏放 case	用 Trace / Eval 推动策略、模型、Prompt 优化



新产物


 风险模式库


 证据标准


 反证标准

 Agent SOP

 Policy 策略约束

 人审决策模板

 Eval 标注集

 复盘报告



定位

从关键问和规则配置者，升级为风险模式、证据标准、反证逻辑、Policy 与 Eval 的设计者。



2 | 算法工程师： 从模型打分到风险信号与证据工程



职责变化

	过去	现在
模型目标	输出分类分数	输出风险信号 + 证据定位 + 置信度
模型形态	单模型打分	多模态模型、Embedding、相似召回、场景识别组合
结果训费方	规则引擎 / 人审系统	Orchestrator、识别 Agent、人审工作台、Eval 系统
评估方式	AUC、召回率、准确率	AUC、误杀、证据质量、Agent 采纳率、处置准确率
数据闭环	标注样本训练	Trace、申诉、人审、反证样本持续训练



重点变化

- 从“分类模型”到“证据模型”
- 从“阈值优化”到“Agent 可用信号优化”
- 补齐反证能力：舞蹈/健身、医疗科普、禁毒宣传、剧情道具等语境识别



定位

从模型分数提供者，升级为多模态风险信号、证据定位、相似召回、反证识别的建设者。



3 | 研发工程师： 从业务系统开发到 Agent 基础设施建设



职责变化

	过去	现在
系统形态	固定流程服务	可编排 Agent 工作流
能力调用	服务间 API	Agent 通过 MCP / Tool Gateway 受控调用
决策逻辑	规则引擎 + 模型阈值	Orchestrator + Agent + Policy 约束
可观测性	日志、埋点	全链路 Trace、工具调用回放、Agent 决策回放
权限与稳定性	服务鉴权 / SLA	Agent 权限、超时、幻觉、越权、工具失败兜底




新增核心工程职责


 Orchestrator


 Agent Runtime


 MCP / Tool Gateway


 Trace

 Eval

 权限控制

 工具调用审计

 Prompt & Policy 版本管理

 降级与兜底



核心原则

- 识别 Agent 只理解风险
- 处置 Agent 必须受 Policy 约束
- 真正执行处罚必须通过 Enforcement
- 高风险 / 灰区必须可进入人审或专项审核



定位

从业务系统开发者，升级为 Agent 编排、工具治理、权限控制、Trace / Eval 与稳定性的基础设施建设者。

协作关系变化



按链路节点看三类角色职责

	策略运营	算法工程师	研发工程师
接入网关	基础风控策略	异常账号 / 设备信号	鉴权、限流、基础拦截
内容预处理	定义证据要求	抽帧、ASR、OCR	预处理服务、素材存储
轻量模型初筛	风险分层阈值	低延迟模型、风险信号	模型接入、超时降级
Orchestrator	进入 Agent / 人审规则	风险等级建议	编排引擎、调用预算
识别 Agent	风险模式、证据、反证标准	模型信号、相似召回、反证模型	Agent Runtime、权限、上下文组装
MCP / Tool Gateway	工具使用边界	模型/向量/图谱工具	工具网关、审计、限流
处置 Agent	动作分级、处罚边界	动作效果评估	Policy 接入、执行工具、防越权
人工审核	审核标准、质检、申诉规则	辅助证据	审核台、任务队列
Trace / Eval	评估指标、复盘标准	Eval 集、效果分析	Trace 存储、回放、看板